

Uma Meta-feature Baseada no Coeficiente de Chatterjee para Seleção de Algoritmos de Agrupamento

Cauê Bittencourt Ângelo dos Santos¹, Davi Vieira Lourenço Correia¹

¹Instituto de Computação – Universidade Federal de Alagoas (UFAL)
Maceió – AL – Brasil

cbas@ic.ufal.br, dvlc@ic.ufal.br

Abstract. *This work investigates a meta-feature for clustering algorithm selection based on Chatterjee’s correlation coefficient. Starting from the CaD characterization proposed by Pimentel and de Carvalho, we replace Spearman’s correlation with Kendall’s coefficient and with a symmetrized version of Chatterjee’s coefficient, which can capture non-monotonic functional dependence. Experiments on 62 OpenML CC-18 datasets indicate that CaD-Chatterjee improves average ranking metrics over CaD-Spearman mainly with k -NN, but this advantage is not statistically significant when results are aggregated by dataset.*

Resumo. *Este trabalho investiga uma meta-feature para seleção de algoritmos de agrupamento baseada no coeficiente de Chatterjee. A partir da caracterização CaD proposta por Pimentel e de Carvalho, substituímos a correlação de Spearman por Kendall e por uma versão simetrizada do coeficiente de Chatterjee, capaz de capturar dependências funcionais não monotônicas. Experimentos em 62 bases da OpenML CC-18 indicam que CaD-Chatterjee melhora métricas médias de ranking em relação ao CaD-Spearman principalmente com k -NN, mas essa vantagem não é estatisticamente significativa quando os resultados são agregados por conjunto de dados.*

1. Introdução

A escolha de um algoritmo de agrupamento é uma etapa central em tarefas de aprendizado não supervisionado. Diferentes algoritmos assumem diferentes vieses sobre a estrutura dos dados: métodos baseados em centroides, como K-Means, favorecem grupos compactos; métodos hierárquicos exploram relações de proximidade; e modelos de mistura gaussiana assumem uma estrutura probabilística. Como consequência, não existe um único algoritmo adequado para todos os conjuntos de dados.

Uma forma de reduzir essa dificuldade é utilizar meta-aprendizado para recomendação de algoritmos. Nessa abordagem, cada conjunto de dados é tratado como uma meta-instância, descrita por meta-features, e o alvo do meta-aprendizado é o desempenho ou o ranking de um conjunto de algoritmos candidatos. Este trabalho parte da proposta de Pimentel e de Carvalho [Pimentel and de Carvalho 2019], que utiliza meta-features baseadas em correlação e dissimilaridade para seleção de algoritmos de agrupamento. No método CaD, pares de instâncias são caracterizados por distância euclidiana e correlação de Spearman [Spearman 1904]; em seguida, a distribuição desses valores é resumida por 19 meta-features estatísticas e baseadas em histogramas.

A hipótese deste trabalho é que substituir Spearman por medidas capazes de capturar relações diferentes pode alterar a caracterização dos dados e, possivelmente, melhorar a recomendação. Em particular, avaliamos o coeficiente de Chatterjee [Chatterjee 2021], uma medida baseada em ranks associada à dependência funcional, incluindo relações não monotônicas. Também avaliamos Kendall [Kendall 1938] como controle, pois é outra medida baseada em ranks voltada principalmente à associação monotônica. As perguntas de pesquisa são: (i) Chatterjee melhora a recomendação em relação a Spearman? (ii) Kendall se comporta de modo semelhante a Spearman? (iii) possíveis ganhos aparecem apenas na similaridade entre rankings ou também na qualidade externa das partições produzidas pelos algoritmos recomendados?

As principais contribuições são a meta-feature CaD-Chatterjee, um protocolo experimental com baselines e teste estatístico agregado por dataset, e a avaliação empírica em 62 bases públicas. Em resumo, CaD-Chatterjee obteve ganhos médios consistentes sobre CaD-Spearman com k-NN, inclusive em métricas sensíveis ao topo do ranking, mas os ganhos não foram estatisticamente significativos na análise por dataset e não se refletiram na qualidade externa das partições.

2. Proposta

O método proposto modifica a etapa de caracterização do CaD. Seja um conjunto de dados D com n instâncias e p atributos numéricos. Cada instância é representada por $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$. Para cada par de instâncias (x_i, x_j) , calcula-se uma medida de dissimilaridade e uma medida de correlação. A dissimilaridade utilizada é a distância euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}. \quad (1)$$

No CaD-Spearman, o componente de correlação é a correlação de Spearman entre os vetores x_i e x_j . Neste trabalho, esse componente é substituído por Kendall e por Chatterjee. O coeficiente de Chatterjee $\xi_n(X, Y)$ mede o quanto Y pode ser previsto como função de X . Em sua forma sem empates, ordenam-se as observações pelo valor de X e calcula-se o rank r_i de Y . Então:

$$\xi_n(X, Y) = 1 - \frac{3 \sum_{i=1}^{n-1} |r_{i+1} - r_i|}{n^2 - 1}. \quad (2)$$

A Equação 2 apresenta a forma sem empates para simplificar a exposição; a implementação usada nos experimentos trata empates nos ranks. Se Y é independente de X , os ranks de Y ficam desorganizados quando ordenados por X , resultando em valores baixos. Se Y é aproximadamente uma função de X , os ranks apresentam maior regularidade e o coeficiente aumenta. Como Chatterjee é assimétrico, isto é, em geral $\xi(x_i, x_j) \neq \xi(x_j, x_i)$, utilizamos uma versão simétrica por média:

$$\xi_{sym}(x_i, x_j) = \frac{\xi(x_i, x_j) + \xi(x_j, x_i)}{2}. \quad (3)$$

Essa escolha evita que a meta-feature dependa da ordem arbitrária das instâncias, mas é uma decisão de projeto cujo impacto não foi avaliado por ablação neste trabalho. Depois do cálculo da correlação e da dissimilaridade, os vetores c e d são concatenados em $m = [c, d]$ e normalizados para $[0, 1]$. A partir de m , extraem-se as mesmas 19 meta-features do CaD: média, variância, desvio padrão, assimetria, curtose, dez frequências de histograma no intervalo $[0, 1]$ e quatro frequências por faixas de Z-score absoluto. A Tabela 1 resume o procedimento completo de extração.

Tabela 1. Procedimento de extração das meta-features CaD-Chatterjee.

Entrada: conjunto de dados D e número máximo de pares M .

Saída: vetor com 19 meta-features.

1. Normalizar os atributos numéricos para $[0, 1]$.
 2. Amostrar até M pares de instâncias (x_i, x_j) .
 3. Para cada par, calcular $d(x_i, x_j)$, $\xi(x_i, x_j)$ e $\xi(x_j, x_i)$.
 4. Obter $\xi_{sym}(x_i, x_j)$ pela média das duas direções.
 5. Concatenar os vetores de correlação e dissimilaridade.
 6. Normalizar o vetor concatenado e extrair as 19 estatísticas finais.
-

3. Metodologia Experimental

Os experimentos foram realizados com conjuntos de dados da suíte OpenML CC-18 [Vanschoren et al. 2013]. Após filtragem, foram utilizados 62 conjuntos. Mantivemos apenas atributos numéricos, removemos linhas com valores ausentes e normalizamos os atributos para $[0, 1]$. Essa decisão simplifica o protocolo, mas limita a generalização para bases categóricas ou mistas.

Foram avaliados cinco algoritmos de agrupamento em nível base: K-Means (KM), Ward Agglomerative Clustering (WA), Average Agglomerative Clustering (AA), Gaussian Mixture com matriz diagonal (GMd) e Gaussian Mixture com matriz completa (GMf), implementados com scikit-learn [Pedregosa et al. 2011]. O número de clusters foi definido como o número de classes conhecido da base. Para viabilizar o custo dos algoritmos hierárquicos e dos índices internos, foi usada subamostragem de no máximo 5000 instâncias por base. Para as meta-features, foram amostrados até 50.000 pares por conjunto de dados.

Os meta-alvos foram construídos a partir dos mesmos 10 índices internos de [Pimentel and de Carvalho 2019]: Calinski-Harabasz, Silhouette, Dunn, Gamma, Tau, Davies-Bouldin, Xie-Beni, SD-Scat, SD-Dis e Ray-Turi. Cada índice produziu um ranking dos cinco algoritmos. Em seguida, os rankings foram agregados por *average ranking*: calcula-se a posição média de cada algoritmo nos índices e reordenam-se os algoritmos por essa média. Esse ranking agregado é usado como ranking verdadeiro.

Foram avaliados quatro conjuntos de meta-features: Distance, CaD-Sp, CaD-Ke e CaD-Ch. O primeiro usa apenas dissimilaridade; os demais usam, respectivamente, Spearman, Kendall e Chatterjee simetrizado por média como componente de correlação. Dois meta-aprendizes foram avaliados: k-NN para ranking, com $k = 5$ e agregação por *average ranking*; e Random Forest (RF) com 100 árvores por alvo, treinada como regres-

são multi-saída. O escalonamento das meta-features foi ajustado apenas no treino de cada fold, evitando *Data Leakage*.

A avaliação usou validação cruzada 10-fold repetida 20 vezes. Também incluímos dois baselines: MeanRank, que recomenda o ranking médio do treino, e MajorityRank, que recomenda o ranking mais frequente. As métricas no nível meta foram: SRC, isto é, a correlação de Spearman entre ranking verdadeiro e recomendado; WRC, uma correlação de ranking ponderada pelo topo baseada em weighted Kendall [Vigna 2015]; NDCG@3 [Järvelin and Kekäläinen 2002]; e Top1Hit, a fração de casos em que o algoritmo recomendado em primeiro lugar é também o melhor no ranking verdadeiro. As métricas externas foram ARI [Hubert and Arabie 1985] e AMI [Vinh et al. 2010], calculadas sobre a partição gerada pelo algoritmo recomendado na primeira posição. Para comparação estatística entre CaD-Sp e as alternativas, usamos Wilcoxon pareado [Wilcoxon 1945] com $\alpha = 0,05$. A análise principal agrega os resultados por conjunto de dados, evitando tratar repetições da validação cruzada como observações independentes.

4. Resultados e Discussão

A Tabela 2 apresenta as métricas de ranking no nível meta. Os baselines obtiveram SRC relativamente alto: 0,636 para MeanRank e 0,640 para MajorityRank. Isso indica uma tendência global nos rankings, tornando os baselines competitivos quando a métrica considera apenas similaridade de ranking.

Tabela 2. Métricas de ranking no nível meta (média $\pm$ desvio padrão).

Método/MF	Aprendiz	SRC	WRC	NDCG@3	Top1Hit
MeanRank	Baseline	0,636 $\pm$ 0,303	0,579 $\pm$ 0,304	0,900 $\pm$ 0,099	0,533 $\pm$ 0,499
MajorityRank	Baseline	0,640 $\pm$ 0,302	0,588 $\pm$ 0,306	0,904 $\pm$ 0,099	0,581 $\pm$ 0,494
Distance	kNN	0,658 $\pm$ 0,267	0,605 $\pm$ 0,288	0,905 $\pm$ 0,084	0,648 $\pm$ 0,478
Distance	RF	0,636 $\pm$ 0,295	0,582 $\pm$ 0,295	0,898 $\pm$ 0,097	0,612 $\pm$ 0,487
CaD-Sp	kNN	0,611 $\pm$ 0,301	0,549 $\pm$ 0,304	0,892 $\pm$ 0,098	0,573 $\pm$ 0,495
CaD-Sp	RF	0,646 $\pm$ 0,277	0,583 $\pm$ 0,283	0,904 $\pm$ 0,090	0,594 $\pm$ 0,491
CaD-Ke	kNN	0,608 $\pm$ 0,327	0,540 $\pm$ 0,320	0,890 $\pm$ 0,103	0,519 $\pm$ 0,500
CaD-Ke	RF	0,625 $\pm$ 0,282	0,570 $\pm$ 0,283	0,900 $\pm$ 0,089	0,580 $\pm$ 0,494
CaD-Ch	kNN	0,644 $\pm$ 0,303	0,586 $\pm$ 0,322	0,904 $\pm$ 0,096	0,627 $\pm$ 0,484
CaD-Ch	RF	0,644 $\pm$ 0,263	0,587 $\pm$ 0,262	0,904 $\pm$ 0,087	0,612 $\pm$ 0,487

Com k-NN, CaD-Ch superou CaD-Sp em SRC (0,644 contra 0,611), WRC (0,586 contra 0,549), NDCG@3 (0,904 contra 0,892) e Top1Hit (0,627 contra 0,573). Portanto, Chatterjee não melhora apenas a correlação global do ranking; ele também melhora, em média, métricas sensíveis ao topo nesse meta-aprendiz. Com RF, o comportamento foi menos consistente: CaD-Ch melhorou ligeiramente WRC e Top1Hit, mas não superou CaD-Sp em SRC, NDCG@3 ou ARI. Já CaD-Ke ficou abaixo de CaD-Sp em quase todas as métricas com os dois meta-aprendizes, e nenhuma diferença entre Kendall e Spearman foi significativa no teste de Wilcoxon por dataset (menor $p = 0,096$, em RF/SRC). Esse resultado é coerente com o papel de controle: trocar uma medida monotônica por outra pouco altera a caracterização.

A Figura 1 mostra a distribuição de SRC por predição. As medianas dos conjuntos são próximas, indicando desempenhos típicos semelhantes. No caso do k-NN, a diferença

entre CaD-Ch e CaD-Sp parece ocorrer principalmente na menor concentração de valores baixos de SRC para CaD-Ch, sugerindo que o ganho médio decorre mais da redução de algumas predições ruins do que de um deslocamento uniforme de toda a distribuição.




Figura 1. Distribuição de SRC por predição na validação cruzada repetida, por conjunto de meta-features e meta-aprendiz.

O conjunto Distance com kNN continuou sendo o mais forte nas métricas de ranking, o que sugere que a dissimilaridade sozinha já carrega muito sinal para reproduzir rankings construídos por índices internos, muitos deles baseados em distância. Esse achado limita a premissa de que o componente de correlação necessariamente agrega informação sobre a dissimilaridade. Por outro lado, a Tabela 3 mostra que os métodos CaD foram mais fortes que Distance em ARI e AMI, especialmente com RF. Assim, reproduzir melhor o ranking interno não implica necessariamente obter a melhor qualidade externa da partição.

Tabela 3. Métricas externas da partição recomendada no topo do ranking.

Método/MF	Aprendiz	ARI	AMI
MeanRank	Baseline	0,1062 ± 0,1707	0,1801 ± 0,2405
MajorityRank	Baseline	0,0999 ± 0,1624	0,1746 ± 0,2383
Distance	kNN	0,1546 ± 0,2244	0,2140 ± 0,2723
Distance	RF	0,1500 ± 0,2229	0,2105 ± 0,2701
CaD-Sp	kNN	0,1644 ± 0,2327	0,2269 ± 0,2753
CaD-Sp	RF	0,1732 ± 0,2376	0,2310 ± 0,2793
CaD-Ke	kNN	0,1699 ± 0,2352	0,2281 ± 0,2758
CaD-Ke	RF	0,1726 ± 0,2377	0,2302 ± 0,2787
CaD-Ch	kNN	0,1640 ± 0,2339	0,2250 ± 0,2822
CaD-Ch	RF	0,1691 ± 0,2353	0,2309 ± 0,2819

A Tabela 4 apresenta os testes de Wilcoxon para a comparação principal CaD-Sp contra CaD-Ch na análise agregada por dataset. Nenhuma comparação foi estatisticamente significativa a $\alpha = 0,05$, mesmo sem correção para múltiplas comparações. O resultado mais próximo foi kNN/NDCG@3, com $p = 0,0578$, mas essa métrica ficou próxima de 0,90 até para os baselines, indicando saturação pelo pequeno número de algoritmos avaliados. Além disso, as medianas das diferenças foram nulas em quase todas as

métricas, sugerindo que os ganhos médios de CaD-Ch são concentrados em uma parcela das bases, e não distribuídos uniformemente.

Tabela 4. Wilcoxon pareado por dataset ($N = 62$) para CaD-Sp vs CaD-Ch. $\Delta = \text{CaD-Ch} - \text{CaD-Sp}$.

Métrica	Δ kNN	p kNN	Δ RF	p RF
SRC	0,0323	0,2962	-0,0021	0,3511
WRC	0,0370	0,2680	0,0035	0,6689
NDCG@3	0,0112	0,0578	-0,0007	0,4040
Top1Hit	0,0540	0,3137	0,0185	0,8953
ARI	-0,0004	0,4683	-0,0042	0,3123
AMI	-0,0019	0,2767	-0,0002	0,8788

Entre as limitações do estudo, destaca-se o regime de poucos atributos. No CaD, a correlação é calculada entre pares de instâncias, isto é, entre vetores definidos sobre os p atributos. Assim, quando p é pequeno, cada coeficiente de correlação é calculado sobre vetores curtos. No conjunto usado, 18 das 62 bases têm $p \leq 10$ e 11 têm $p \leq 6$, o que limita a exploração das propriedades assintóticas do coeficiente de Chatterjee e pode ter contribuído para a ausência de superioridade robusta. Além disso, o conjunto de algoritmos avaliados foi menor que o de Pimentel e de Carvalho [Pimentel and de Carvalho 2019]: enquanto o trabalho original considera dez candidatos, este estudo avaliou os cinco descritos na Seção 3. Essa redução diminui o custo computacional, mas restringe a diversidade de vieses de agrupamento, torna parcial a comparação com o protocolo original e favorece a saturação de métricas de topo, como observado no NDCG@3. Outras limitações incluem o uso do número real de classes como número de clusters, a remoção de atributos categóricos, a dependência dos meta-alvos em relação a índices internos e a amostragem de pares.

5. Conclusão

Este trabalho investigou uma meta-feature para seleção de algoritmos de agrupamento baseada na substituição da correlação de Spearman pelo coeficiente de Chatterjee no método CaD. A proposta foi avaliada em 62 bases da OpenML CC-18, com cinco algoritmos de agrupamento, 10 índices internos, quatro conjuntos de meta-features, dois meta-aprendizes e dois baselines.

Os resultados respondem às três perguntas de pesquisa. (i) CaD-Chatterjee é competitivo com CaD-Spearman e, com k-NN, apresentou ganhos médios em SRC, WRC, NDCG@3 e Top1Hit, sugerindo melhor caracterização do ranking e do topo da recomendação; entretanto, esses ganhos não foram significativos na análise por dataset. (ii) Kendall comportou-se de modo estatisticamente indistinguível de Spearman, reforçando seu papel de controle: os ganhos médios observados com Chatterjee não parecem decorrer apenas da troca por outra medida monotônica. (iii) Os ganhos observados ficaram restritos às métricas de ranking; não se refletiram consistentemente em ARI e AMI, e com Random Forest CaD-Spearman foi ligeiramente superior ou equivalente na maior parte das métricas. Além disso, Distance puro continuou muito competitivo no nível meta, mostrando que o componente de correlação não agregou ganho sistemático sobre a dissimilaridade neste protocolo.

Assim, a hipótese de que Chatterjee melhora a recomendação recebeu suporte parcial. A medida mostrou potencial, mas os experimentos não fornecem evidência suficiente para afirmar superioridade robusta em relação ao Spearman. Como trabalhos futuros, recomenda-se: estratificar os resultados pelo número de atributos; avaliar outras simetizações, como o máximo entre as direções; testar outros tamanhos de amostragem de pares; incluir bases mistas; e ampliar o conjunto de algoritmos.

Declaração de Uso de Inteligência Artificial Generativa

Declaro que a ferramenta de Inteligência Artificial Generativa Claude (Anthropic) foi utilizada como apoio às etapas de planejamento experimental, revisão metodológica, discussão de métricas de avaliação e dos resultados, elaboração de scripts e apoio à redação deste trabalho. Todas as sugestões, análises, códigos e trechos textuais produzidos com auxílio da ferramenta foram revisados criticamente, adaptados quando necessário e validados pelo autor com base nos dados, experimentos e literatura pertinente. O autor assume integral responsabilidade pela concepção, execução, análise dos resultados, redação final e veracidade das informações apresentadas neste trabalho, em conformidade com a Portaria CNPq nº 2.664/2026 [Conselho Nacional de Desenvolvimento Científico e Tecnológico 2026].

Referências

- Chatterjee, S. (2021). A new coefficient of correlation. *Journal of the American Statistical Association*, 116(536):2009–2022.
- Conselho Nacional de Desenvolvimento Científico e Tecnológico (2026). Portaria CNPq nº 2.664, de 6 de março de 2026. Diário Oficial da União, 11 mar. 2026. Disponível em: <https://www.in.gov.br/web/dou/-/portaria-cnpq-n-2.664-de-6-de-marco-de-2026-691779232>. Acesso em: 11 jun. 2026.
- Hubert, L. and Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1):193–218.
- Järvelin, K. and Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446.
- Kendall, M. G. (1938). A new measure of rank correlation. *Biometrika*, 30(1/2):81–93.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Pimentel, B. A. and de Carvalho, A. C. P. L. F. (2019). A new data characterization for selecting clustering algorithms using meta-learning. *Information Sciences*, 477:203–219.
- Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1):72–101.
- Vanschoren, J., van Rijn, J. N., Bischl, B., and Torgo, L. (2013). OpenML: Networked science in machine learning. *SIGKDD Explorations*, 15(2):49–60.

- Vigna, S. (2015). A weighted correlation index for rankings with ties. In *Proceedings of the 24th International Conference on World Wide Web*, pages 1166–1176.
- Vinh, N. X., Epps, J., and Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. *Journal of Machine Learning Research*, 11:2837–2854.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.