


Uma Meta-feature Baseada no Coeficiente de Chatterjee para Seleção de Algoritmos de Agrupamento



Cauê Bittencourt e Davi Vieira



0 artigo base: Pimentel e de Carvalho (2019)

CaD = **C**orrelation and **D**issimilarity:

- para cada par de instâncias: distância euclidiana + correlação de Spearman;
- vetor concatenado $m = [c, d]$, normalizado;
- 19 meta-features: 5 estatísticas + 10 bins de histograma + 4 faixas de |Z-score|.

Resultado deles: CaD venceu meta-features estatísticas, de distância e de avaliação em 219 datasets.

Nossa proposta: trocar o Spearman

Pergunta central: Spearman captura associação **monotônica**. E se a relação entre instâncias for funcional mas não monotônica?

Duas substitutas:

Kendall τ (1938): também rank-based, também monotônica → **controle**.

Chatterjee ξ (2021): rank-based, detecta dependência **funcional** (inclusive não monotônica)

$$\xi_n(X, Y) = 1 - \frac{3 \sum_{i=1}^{n-1} |r_{i+1} - r_i|}{n^2 - 1}, \quad \xi \approx 1 \text{ quando } Y \approx f(X), \quad \xi \approx 0 \text{ sob independência}$$

$\xi_{\text{sym}} = (\xi(x,y) + \xi(y,x))/2$. (versão usada)

Perguntas de pesquisa

- (i) Chatterjee melhora a recomendação em relação a Spearman?
- (ii) Kendall se comporta de modo semelhante a Spearman?
- (iii) possíveis ganhos aparecem apenas na similaridade entre rankings ou também na qualidade externa das partições produzidas pelos algoritmos recomendados?

Protocolo experimental: visão geral

Adaptação necessária: study 88 do OpenML (usado por Pimentel) não está mais disponível via API → **CC-18** (72 datasets → 62 após filtro)

Pipeline:

(1) datasets → (2) meta-alvos: 5 algoritmos × 10 índices internos → average ranking → (3) 4 conjuntos de MFs (Distance, CaD-Sp, CaD-Ke, CaD-Ch; 50 mil pares/base) → (4) meta-aprendizado: kNN (k=5) e RF (T=100), 10-fold CV × 20 repetições, baselines MeanRank/MajorityRank e testes de Wilcoxon

Tudo público: código no GitHub, dados via OpenML, seeds fixos

Como os meta-alvos foram gerados

Problema: O meta-aprendizado precisa de um “ranking verdadeiro” de algoritmos para cada base. Como clustering é não supervisionado, esse ranking não vem diretamente de uma acurácia como vimos em sala.

Construção do meta-alvo:

Para cada base:

1. executar os 5 algoritmos;
2. calcular os 10 índices internos;
3. ranquear os algoritmos em cada índice;
4. agregar os 10 rankings por average ranking;
5. obter o ranking de referência.

Extração das meta-features e avaliação

Extração das meta-features: Para cada base, amostramos até 50.000 pares de instâncias.

- Para cada par:
 - calcular dissimilaridade euclidiana;
 - calcular correlação/dependência entre as instâncias.
- Depois: lógica do CaD explicada anteriormente

Meta-aprendiz: kNN e Random Forest

Avaliação:

Validação cruzada: 10 folds $\times$ 20 repetições.

SRC, WRC, NDCG@3, Top1Hit (Métricas de ranking) e ARI, AMI (Métricas externas)

Resultados: métricas usadas no artigo base

Método/MF	Aprendiz	SRC	ARI	AMI
MeanRank	Baseline	$0,636 \pm 0,303$	$0,1062 \pm 0,1707$	$0,1801 \pm 0,2405$
MajorityRank	Baseline	$0,640 \pm 0,302$	$0,0999 \pm 0,1624$	$0,1746 \pm 0,2383$
Distance	kNN	$0,658 \pm 0,267$	$0,1546 \pm 0,2244$	$0,2140 \pm 0,2723$
Distance	RF	$0,636 \pm 0,295$	$0,1500 \pm 0,2229$	$0,2105 \pm 0,2701$
CaD-Sp	kNN	$0,611 \pm 0,301$	$0,1644 \pm 0,2327$	$0,2269 \pm 0,2753$
CaD-Sp	RF	$0,646 \pm 0,277$	$0,1732 \pm 0,2376$	$0,2310 \pm 0,2793$
CaD-Ke	kNN	$0,608 \pm 0,327$	$0,1699 \pm 0,2352$	$0,2281 \pm 0,2758$
CaD-Ke	RF	$0,625 \pm 0,282$	$0,1726 \pm 0,2377$	$0,2302 \pm 0,2787$
CaD-Ch	kNN	$0,644 \pm 0,303$	$0,1640 \pm 0,2339$	$0,2250 \pm 0,2822$
CaD-Ch	RF	$0,644 \pm 0,263$	$0,1691 \pm 0,2353$	$0,2309 \pm 0,2819$

Resultados: considerando o topo do ranking

Método/MF	Aprendiz	WRC	NDCG@3	Top1Hit
MeanRank	Baseline	$0,579 \pm 0,304$	$0,900 \pm 0,099$	$0,533 \pm 0,499$
MajorityRank	Baseline	$0,588 \pm 0,306$	$0,904 \pm 0,099$	$0,581 \pm 0,494$
Distance	kNN	$0,605 \pm 0,288$	$0,905 \pm 0,084$	$0,648 \pm 0,478$
Distance	RF	$0,582 \pm 0,295$	$0,898 \pm 0,097$	$0,612 \pm 0,487$
CaD-Sp	kNN	$0,549 \pm 0,304$	$0,892 \pm 0,098$	$0,573 \pm 0,495$
CaD-Sp	RF	$0,583 \pm 0,283$	$0,904 \pm 0,090$	$0,594 \pm 0,491$
CaD-Ke	kNN	$0,540 \pm 0,320$	$0,890 \pm 0,103$	$0,519 \pm 0,500$
CaD-Ke	RF	$0,570 \pm 0,283$	$0,900 \pm 0,089$	$0,580 \pm 0,494$
CaD-Ch	kNN	$0,586 \pm 0,322$	$0,904 \pm 0,096$	$0,627 \pm 0,484$
CaD-Ch	RF	$0,587 \pm 0,262$	$0,904 \pm 0,087$	$0,612 \pm 0,487$

Teste estatístico

Comparação principal

- CaD-Sp vs CaD-Ch;
- Teste: Wilcoxon pareado.

Dois escopos: por execução/fold e por dataset.

Análise principal: por dataset (N=62)

Resultado por dataset

- Nenhuma métrica significativa;
- Menor p-valor: kNN/NDCG@3, ($p=0,0578$);
- Medianas das diferenças próximas de zero.

Limitações principais

- Poucos atributos em várias bases;
- No CaD, a correlação é calculada entre vetores de atributos das instâncias;
- Menos algoritmos candidatos: 5 neste trabalho vs. 10 no artigo original;
- K oracular: número real de classes usado como número de clusters;
- Apenas atributos numéricos;
- Meta-alvos dependem de índices internos;
- Amostragem de até 50 mil pares;
- Simetrização por média não foi ablada.

Conclusões

(i) Chatterjee melhora Spearman?

- Parcialmente.
- Ganhos médios com kNN, inclusive no topo.
- Sem significância por dataset.

(ii) Kendall se comporta como Spearman?

- Sim, de forma geral.
- Reforça o papel de controle monotônico.

(iii) O ganho aparece em ARI/AMI?

- Não de forma consistente.
- Melhoras aparecem mais nas métricas de ranking.

Trabalhos futuros e encerramento

- Estratificar resultados por número de atributos;
- Testar se CaD-Ch melhora mais em bases com p maior;
- Fazer ablação da simetrização:
 - média vs máximo;
 - outras combinações.
- Variar o número de pares amostrados;
- Incluir bases mistas/categóricas;
- Ampliar o conjunto de algoritmos candidatos;
- Aumentar o n de datasets;
- Datasets com mais colunas;
- Repositório público no GitHub.

Obrigado!



Dúvidas?